IBA
PNU Business School
Intelligent Business Analytics

German Credit Risk

SVC(RBF) 신용 RISK 예측 모델



I 발표자 : 서인규 / 팀원 이영진, 최희찬, 조현빈

CONTENT

1

데이터 이해

프로젝트 목표
EDA

2

데이터 전처리 및 모델 설계

변수 전처리
Scaling

3

모델 학습 및 성능 최적화

모델링
임계값 최적화
하이퍼파라미터
클래스 가중치
최종 결과

4

기존 모델 비교 및 결론

모델 변천사
한계 및 결론

CHAP 01. 데이터 이해

프로젝트 목표

IBA
PNU Business School
Intelligent Business Analytics

Risk 예측

위험 고객(bad)을 찾아내는 모델

입력 변수

Age · Sex · Job · Housing · Checking account

Saving accounts · Credit amount · Duration · Purpose

목표 변수

Risk = good / bad

800	200	9
학습 데이터	예측 데이터	입력 변수

[bad] F1-score

$$\frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

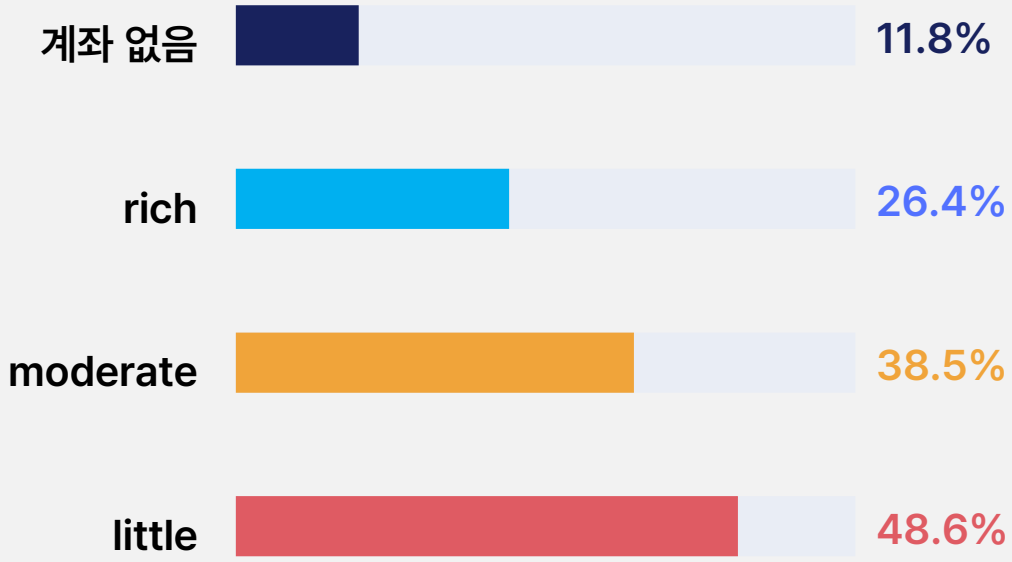
학습 클래스 분포



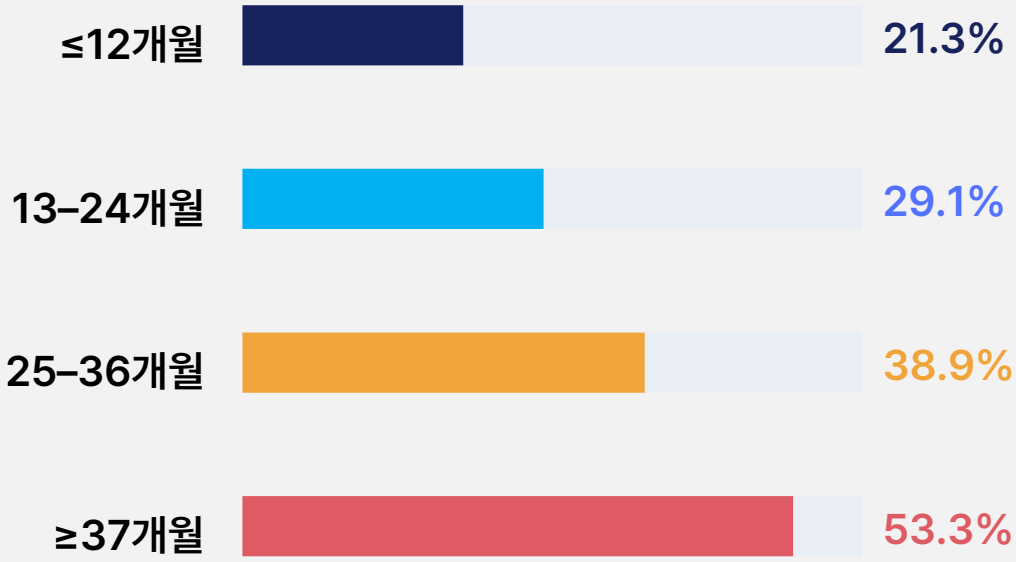
good 560명 · 70%　　bad 240명 · 30%

대표변수의 bad 비율

Checking account의 bad 비율



Duration의 bad 비율



변수의 bad 비율에서 위험 경향 확인
하지만 도메인 특성상 여러 변수 조합과 상호작용 반영한 비선형 경계 필요

CHAP 02. 데이터 전처리 및 모델 설계

변수 전처리

IBA
PNU Business School
Intelligent Business Analytics

전처리 선택

변수	타입	전처리	선택 근거
Job	명목형	원핫 인코딩	0~3으로 된 직업 코드
Saving/Checking account	순서+상태정보	상태 플래그	잔고 순서 보존 미보유·미상태 별도 구분
Sex / Housing / Purpose	명목형	원핫 인코딩	범주간 순서 및 거리정보 x
Age / Credit amount /Duration	수치형	표준화	거리 계산에서 단위 차이가 미치는 영향 방치

데이터의 저장 형태가 아닌 변수의 실제 의미와 측정 척도에 맞춰 전처리
범주 간 잘못된 순서 부여 및 정보 손실 방지

변수 전처리

Saving, Checking account 처리

Saving accounts



Checking account



saving account와 checking account 결측치 값 none

독일 신용도 원자료에서
checking account-> 거래계좌 없음
saving account -> unknown/계좌 없음
none 값으로 별도 범주로 지정

칼럼을 분리하는 이유

계좌를 모르면 잔고를 알 수 없음

"미보유"는 금액 척도가 아님 차원이 다른 상태

Checking account경우 moderate와 none 구분 불가

Scaling

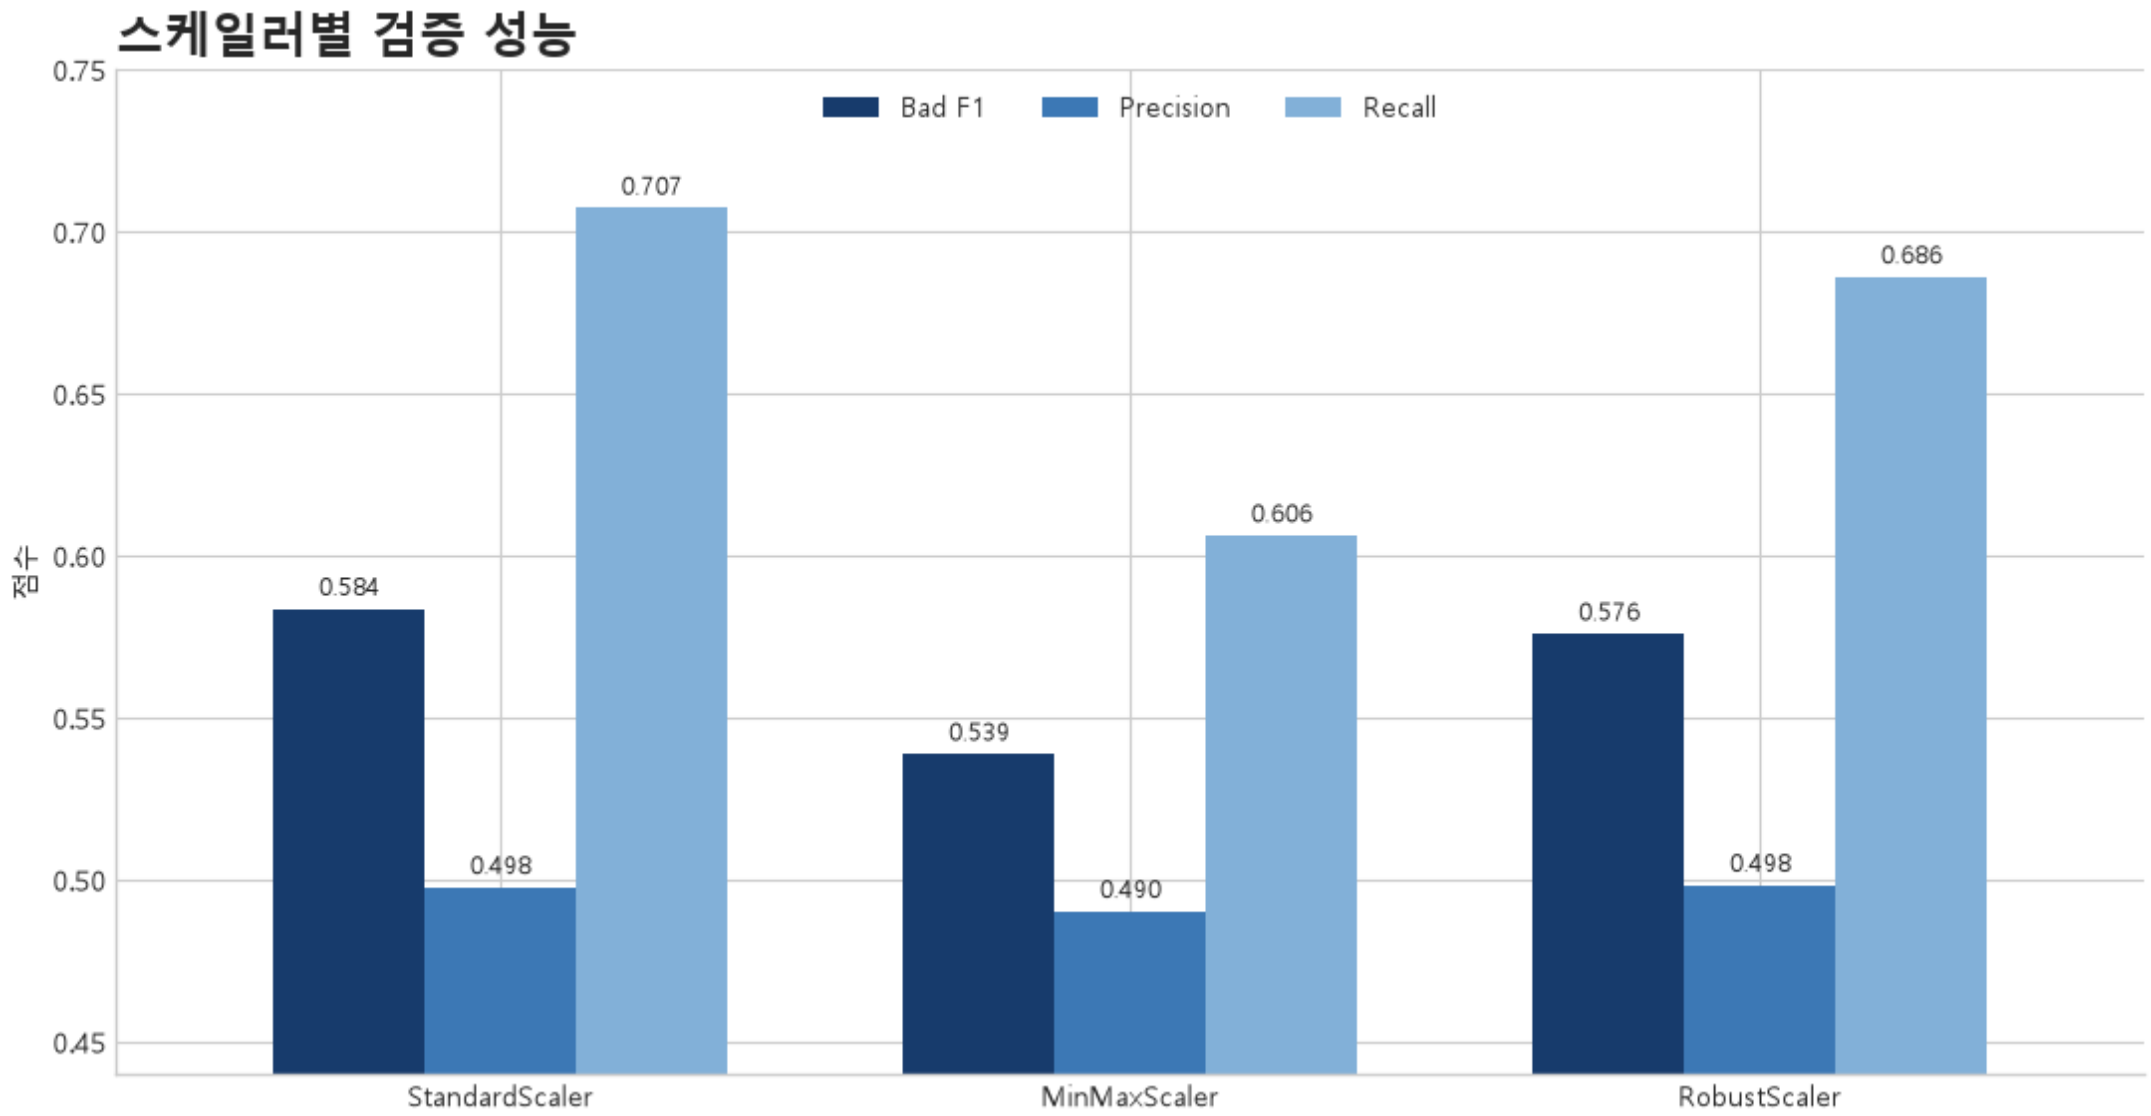
StandardScaler

IBA
PNU Business School
Intelligent Business Analytics

StandardScaler	MinMaxScaler	RobustScaler
F1 score 0.584	F1 score 0.539	F1 score 0.576
평균과 표준편차를 이용한 스케일링 이상치의 영향을 줄이지 않음	최솟값과 최댓값을 0~1 사이로 스케일링 극단값에 대한 정보 손실	중앙값 빼고 IQR로 나눈 스케일링 극단값에 대한 정보 손실

Scaling

StandardScaler



CHAP 03. 모델 학습 및 성능 최적화

모델링

SVC(RBF)모델

SVC | Support Vector Classifier

- 결정경계 근처의 Support Vector를 중심으로 학습
- 데이터가 많지 않고 변수 차원이 일정 수준 이하일 때 유효한 후보
- 결정점수와 임계값 조정으로 F1 Score 최적화 가능

RBF Kernel | 비선형 결정경계

- 직선으로 나누기 어려운 신용위험 패턴을 곡면 경계로 분류
- 변수 간 비선형 관계와 상호작용을 반영
- C · gamma 조정으로 과적합과 일반화 성능을 제어

① risk 분류 데이터

데이터 - 비선형적 / 변수간 관계 - 복잡
→ 곡면으로 분류

② 800건의 적은 표본수

RBF의 느린 연산 속도
→ 800건의 비교적 적은 수의 표본

③ F1 Score의 임계값 지표

Precision · Recall의 균형
→ 임계값 조정으로 F1 개선

학습 800건 중 521건(good 292 / bad 229)이 서포트 벡터 — 표본의 65%가 경계 근처에 존재

임계값

임계값 최적화

1단계 — 순위 변환

점수 절댓값 → 상대 위치 변경
fold 간 분포 차이의 영향을 제거
원점수 0.5778 → 순위 0.5856 (+0.0078)

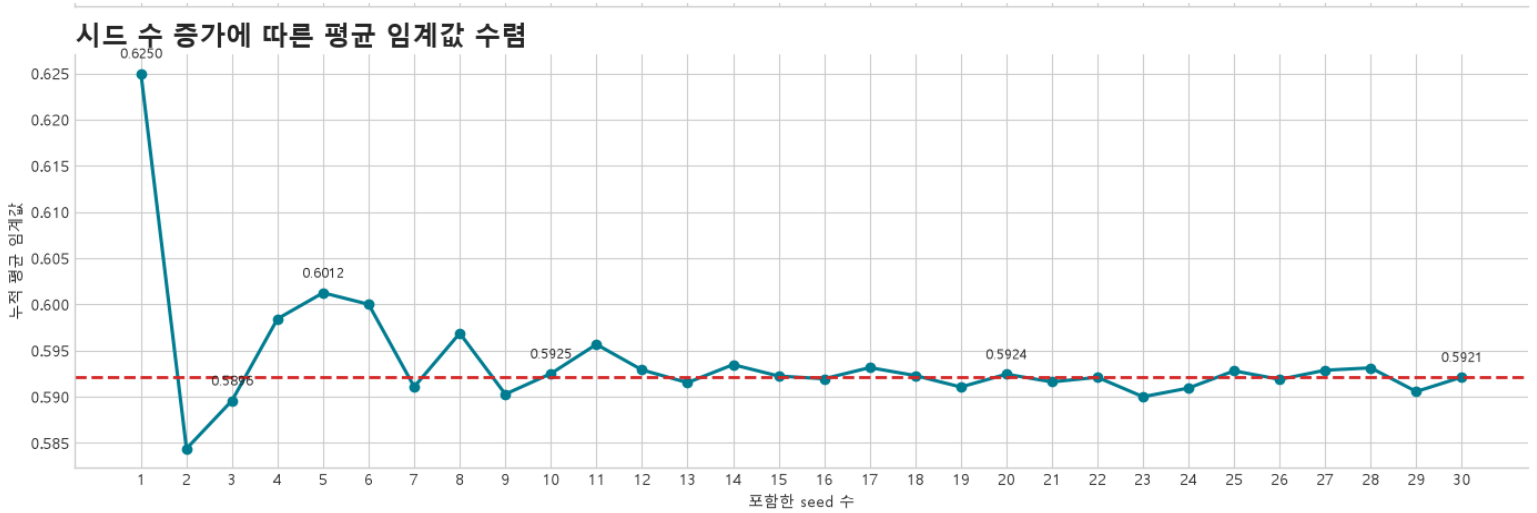
2단계 — train fold 탐색

test fold의 정답은 사용하지 않음
0.02 ~ 0.99 사이를 0.005 간격으로 훑어 194개 후보 중 F1 최대점을 선택

3단계 — OOF 평균

OOF : 각 표본이 자신이 학습에 쓰이지 않은 fold에서 받은 점수

30번 반복해 분할 노이즈를 평균으로 상쇄함



평균에 사용한 시드 개수	1	3	5	10	20	30
확정 임계값	0.6250	0.5896	0.6012	0.5925	0.5924	0.5921

확정 임계값 0.5921
= 예측 대상 집단 내 위험도 상위 40.8%를 bad로 분류

하이퍼파라미터

SVC(RBF)모델

C 7수준 × gamma 5수준 = 35개 조합을 동일한 5-fold(seed 42)로 평가

C — 오분류 벌점

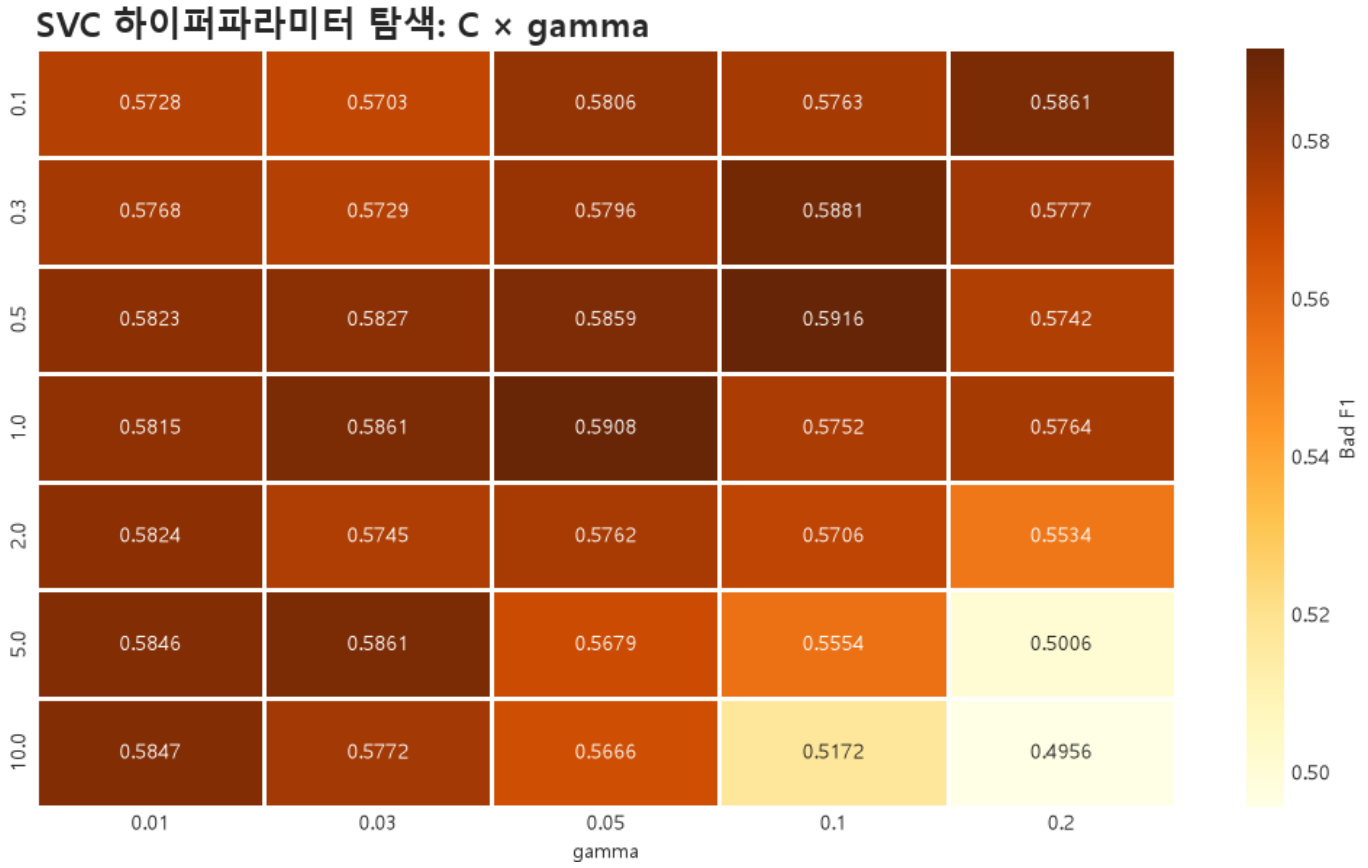
크면 경계가 개별 관측치를 피해 구불구불해짐

gamma — 커널 영향 반경

크면 각 관측치의 영향 반경이 좁아져 경계가 쪼개짐

능선 판독

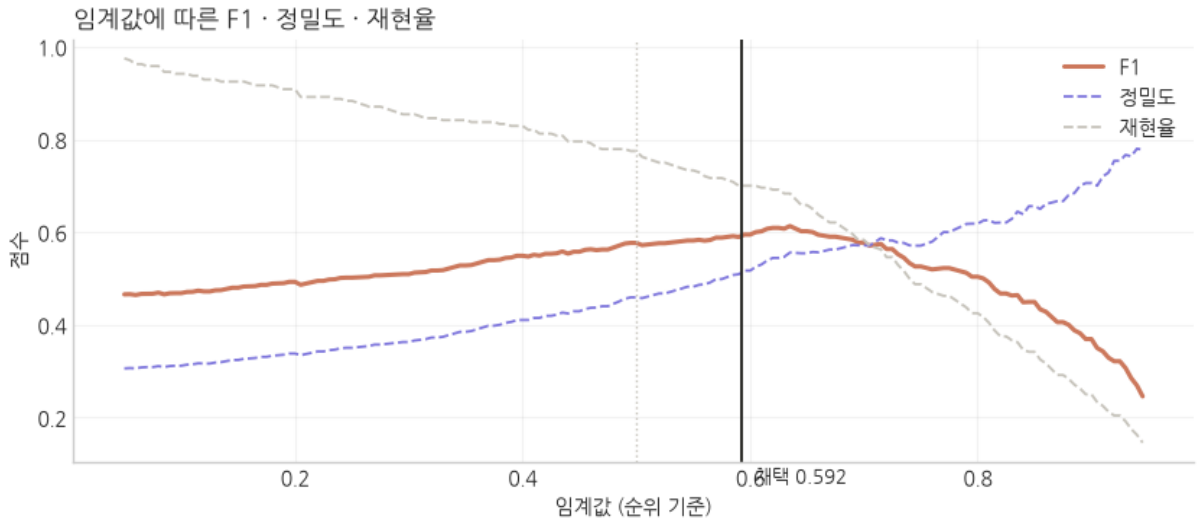
- 좌상단 (C=0.1, γ=0.01) — 복잡도 부족 : **0.5728**
- 우하단 (C=10, γ=0.2) — 복잡도 과다 : **0.4956**
- 격자 최고점은 **C=0.5, γ=0.1 (0.5916)** — 채택안과 일치



임계값

임계값 선정

절단 비율	정밀도	재현율	F1
상위 25%	0.62	0.52	0.565
상위 30%	0.60	0.60	0.600
상위 41% (채택)	**0.53**	**0.72**	**0.610**
상위 50%	0.47	0.78	0.586



0.4552
임계값 0.5 고정

+0.1284
개선폭

0.5836
최종값

임계값

class_weight

class_weight	임계값 0	임계값 최적화
None (채택)	0.4073	**0.5836**
balanced	0.5701	0.5541

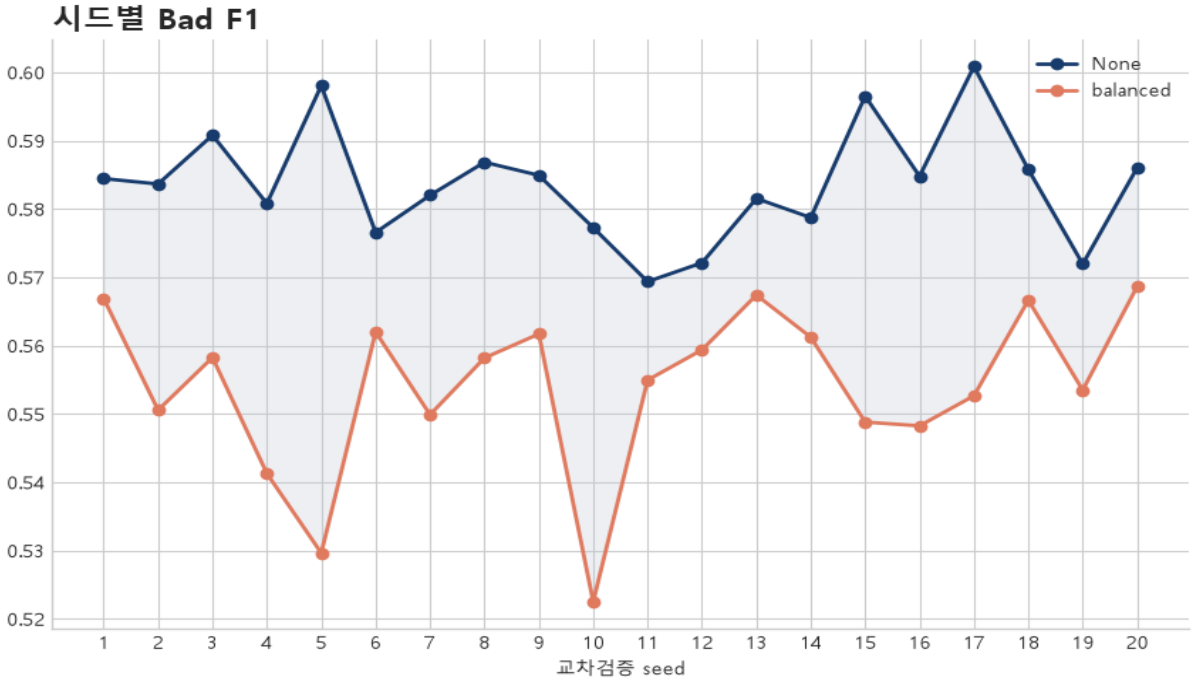
class_weight	Bad F1	Precision	Recall
None (채택)	**0.5836**	**0.498**	**0.707**
balanced	0.5541	0.513	0.608

class_weight = 'balanced'를 적용하면

클래스별로 C 값이 다르게 적용

bad의 C가 2.33배 **0.5 → 1.17**

문제 복잡도 증가



클래스 가중치와 임계값 조정은 개입 지점만 다를 뿐 목적 동일
class_weight 적용하지 않으며 임계값 최적화

최종 결과

최종 모델의 F1 Score

20시드 × 5-fold 평균

평가 지표	Good	Bad
정밀도 (Precision)	0.8472	0.4977
재현율 (Recall)	0.6932	0.7073
F1 Score	**0.7621**	**0.5836**

훈련 데이터 F1 Score **0.7621 / 0.5836**

정답 데이터 예측

118	82	200
예측 good	예측 bad	합계

정답 데이터 F1 Score **0.6761**

CHAP 04. 기존 모델 비교 및 결론

모델 변천사

IBA
PNU Business School
Intelligent Business Analytics

단일·앙상블·최종 모델

단일 모델	앙상블 모델	최종 모델
CatBoost RandomForest Logistic Regression	RF + CatBoost Logistic + RF RF + ET + SVM	Support Vector Classifier (RBF)
최대 F1 Score **0.5316**	최대 F1 Score **0.5897**	최대 F1 Score **0.5836**

여러가지 단일 모델과 이를 조합한 앙상블 모델의 최대 F1 Score을 비교했을 때
앙상블의 F1 Score가 최고값

모델 변천사

IBA
SNU Business School
Intelligent Business Analytics

전환 과정

	관찰	시도	기대
단일 모델 → 앙상블	RF·CatBoost·로지스틱은 bad 탐지 성향이 다름 단일 모델만으로는 놓치는 사례 발생	서로 다른 예측을 평균·다수결·스태킹으로 결합 5개 모델의 26개 조합을 같은 검증 절차에서 비교	한 모델이 놓친 bad를 다른 모델이 보완해 정밀도와 재현율의 균형을 높일 수 있는가?
앙상블 → SVC 실험	앙상블은 여러 예측을 합치는 방식 결정 경계 자체를 다르게 학습하는 후보도 필요	RBF-SVC로 비선형 경계를 학습하고 결정점수 순위와 판정 임계값을 조정	모델을 결합하지 않아도 위험 순서를 구분하고 bad 판정을 개선할 수 있는가?

전환의 핵심 | 다른 모델의 결함을 파악해 결정 경계의 변화 시도

모델 변천사

기본 · 튜닝 · 최종

IBA
PNU Business School
Intelligent Business Analytics

SVM 기본 설정

C = 1.0
gamma = 'scale'
임계값 0.5 (predict 기본)
계좌 변수 원핫

최대 F1 Score
0.4441

SVM 튜닝

C = 1.0
gamma = 'scale'
임계값 0.5842 (최적화)
계좌 변수 원핫

최대 F1 Score
0.5685

+0.1244

SVM 최종 모델

C = 0.5
gamma = 0.1
임계값 0.5921 (30시드 OOF)
계좌 변수 순위 + 플래그

최대 F1 Score
0.5836

+0.0151

개선의 대부분은 “모델을 바꾼 것”이 아니라 “입력을 제대로 구성하고 출력을 제대로 절단한 것”

IBA
SNU Business School
ntelligent Business Analytics

SVC 단계별 전환 근거

모델은 유지, 판정 기준과 입력 표현을 순서대로 개선

	관찰	변경	결과
01 **기본형 → 임계값 조정**	기본 판정의 Bad F1이 0.4441. bad 비율 약 30%에서 판정 기준을 점검할 필요	원핫 변수와 C·γ는 그대로 두고 SVC 점수의 순위 기반 판정 임계값을 탐색	Bad F1 0.5685 (+0.1244). 가장 큰 개선은 모델 교체가 아니라 bad 판정 기준에서 나옴
02 **임계값 조정 → 최종 설정**	원핫만으로 표현한 계좌 정보와 기존 결정 경계를 더 개선할 수 있는지 확인	계좌 수준을 순위·결측 플래그로 표현하고 C·γ를 비교. 30시드 OOF 평균 임계값 0.5921을 적용	Bad F1 0.5836 (+0.0151). 여러 변경을 함께 적용한 결과여서 각 변경의 단독 기여는 분리해 말할 수 없음

전환 원칙 | SVC를 유지하면서 실제 검증 점수로 판정 기준과 입력 표현을 조정

IBA
ㄱNU Business School
ntelligent Business Analytics

최종 SVC의 한계와 후속 분석

현재 가장 유용한 후보이지만, bad를 완전히 구분할 정보와 독립 검증은 부족

입력 정보의 한계	현재 9개 설명 변수만 사용. 신용 이력·고용 기간·기존 부채 같은 정보가 없어 비슷한 신청자 사이의 차이를 설명하기 어려움	추가 신용·상환 관련 변수를 확보하고, 변수 추가 전후 Bad F1과 오분류를 동일 검증으로 비교
bad 오분류	20시드 × 5-fold 기준 Bad F1 = 0.5836, 재현율 = 0.7073 일부 bad 사례는 good과 입력 패턴이 겹침	놓친 bad 사례를 묶어 공통 패턴을 분석하고, 정밀도·재현율의 비용에 맞춰 판정 기준을 다시 정하기
임계값·일반화	순위 임계값 0.5921은 평가 집단의 점수 분포에 영향을 받는다. 같은 800명에서 여러 설정을 탐색해 낙관 편향도 가능함	확률 보정 또는 고정 절대 임계값을 검토하고, 독립된 라벨 데이터나 중첩 CV로 최종 성능 재검증